

实验 1 作业要求

1. 酒店评论数据清洗与特征提取
- (1) 选择你想分析的酒店

(2) 缺失值重复值处理

(3) 日期格式、数值提取、对数计算、模糊房型映射等
2. 调用大模型 API 完成数据扩展（选做：模型一致性评估）
- (1) 评论质量评分（低质量评论过滤）

(2) 评论类别划分（不超过 3 类）

(3) 类别摘要生成

(4) 反向 Query 生成

扩展数据参考：

#	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
1	_id	comment	images	score	publish_date	room_type	fuzzy_room_type	travel_type	comment_len	log_comment_len	useful_count	log_useful_count	review_count	log_review_count	quality_score	categories			
2	680278950	房间非常好 装修很豪华 华一开 始看评论 看酒店 自己拍的照 感觉跟快捷酒 店一样 有些 害怕 但来之 后 真的很 惊喜 装修很 漂亮 很豪华 跟一些老牌的 日系酒店 (帝国酒店) 之类的感觉 差不多 装修 也很豪华 但 时间很长但 装修跟得上 的酒店。 服务很好！ 门童很友好 来开门 比一 些国际连锁的 云里雾里多了 。 退房时候 liron还帮忙 搬行李 退房 不用排队 了。什么时候	["https://	5	2025/4/5	红棉大床客房	客房	源康亭子	320	5.77144112313001	0	0	7.2	07944154167983	9	['整体满意度', '餐饮服务', '前台服务']			

分类体系参考：

- ✓ 设施类：房间设施、公共设施、餐饮设施
- ✓ 服务类：前台服务、客房服务、退房/入住效率
- ✓ 位置类：交通便利性、周边配套、景观/朝向
- ✓ 价格类：性价比、价格合理性
- ✓ 体验类：整体满意度、安静程度、卫生状况

反向 Query 数据参考：

#	A	B	C	D	E	F
1	query	comment_id	comment	room_type	fuzzy_room_type	
2	这家酒店	680278950	房间非常好 装修很豪华 华一开 始看评论 看酒店 自己拍的照 感觉跟快捷酒 店一样 有些 害怕 但来之 后 真的很 惊喜 装修很 漂亮 很豪华 跟一些老牌的 日系酒店 (帝国酒店) 之类的感觉 差不多 装修 也很豪华 但 时间很长但 装修跟得上 的酒店。 服务很好！ 门童很友好 来开门 比一 些国际连锁的 云里雾里多了 。 退房时候 liron还帮忙 搬行李 退房 不用排队 了。什么时候	红棉大床客房	客房	

3. 思考题 1

完成下方 8 道题目，挑选感兴趣的小题或课堂中提到的其他内容，写写自己的思考，下一节课上可能进行讨论（其他题目的答案不用提交）

4. 提交内容汇总

- (1) 调 API 的 ipynb 代码，提交到“实验课作业”
- (2) 个人思考（文档内写上姓名），提交到“独立思考/实验思考题”

5. 截止时间：3/30 23:59

思考题 1

1. 预训练-微调范式在 CV 领域率先诞生，但是大模型却率先诞生于 NLP 领域，这是为什么？
2. BERT 在各项 NLP 任务中均领先早期 GPT，为何当下 Decoder-only 却成为了大模型的主流架构，而不是另外两种？
3. 为什么 BERT 预训练时的 Next Sentence Prediction 任务后续被去除了？句子间的逻辑关系不重要吗？取而代之的是什么？
4. 如何从 BERT 的视角来理解 Diffusion LLM？
5. 传统的位置编码是将表征位置信息的三角函数直接与 Embedding 相加，这种操作会干扰原始 Embedding 的信息吗？
6. 为什么 RMSNorm 逐渐取代 LayerNorm？Pre-Norm 和 Post-Norm 的优劣？
7. Temperature 并非由大模型首创，而是在对比学习中先被广泛应用，Temperature 在对比学习中的作用是什么？
8. ViT 在大规模数据集上训练的表现优于 CNN，但在小规模数据集上不如 CNN，原因是什么？